

ÇOKLU AJANLI DQN İLE LİMAN KONTEYNER İSTİFLEME VE ENGEL YÖNETİM SİSTEMİ

24462877011 Furkan YAŞA

17.07.2026

Özet

Bu çalışmada, liman konteyner sahalarında operasyonel verimliliği artırmak amacıyla derin pekiştirmeli öğrenme (DQN) tabanlı çok ajanlı bir konteyner istifleme ve engel yönetim sistemi geliştirilmiştir. İlk olarak, tek bir otonom vincin (Vinç-1) konteynerleri toplama, istifleme ve önceliklendirme kurallarını (rotasyon, üst üste istifleme, renk hiyerarşisi) öğrenmesi sağlanmıştır. Daha sonra, büyük ölçekli bir sahada (10x10 grid, 18 konteyner) eğitim süresinin aşırı uzaması ve politikanın yakınsamaması nedeniyle, sisteme ikinci bir yardımcı vinç (Vinç-2) entegre edilmiştir. Vinç-2, öncelikle kural tabanlı bir uzman sistem olarak çalıştırılmış, ardından bağımsız bir DQN ajanına dönüştürülerek tam otonom bir multi-agent DQN mimarisi elde edilmiştir. Deneysel sonuçlar, küçük ölçekli (5x13) çok ajanlı sistemin başarıyla eğitilebildiğini ve vinçlerin iş birliği içinde çalışarak engelleri dinamik olarak kaldırabildiğini göstermektedir. Büyük ölçekli (10x10) sistemin eğitim süresinin pratik sınırları aştığı gözlemlenmiş olup, bu durum ölçeklenebilirliğin önemli bir araştırma problemi olduğunu teyit etmektedir.

1. GİRİŞ

Küresel ticaret hacmindeki artış, limanların operasyonel verimliliğini kritik bir rekabet unsuru haline getirmiştir. Özellikle konteyner terminallerinde, istif sahasındaki (yard) yükleme, boşaltma ve istifleme süreçleri, tedarik zincirinin akıcılığını doğrudan etkileyen darboğazlardır. Geleneksel olarak bu süreçler, insan operatörler veya basit sezgisel (heuristic) kurallara dayalı yarı-otonom sistemler tarafından yönetilmektedir. Ancak, farklı boyut, ağırlık ve önceliğe sahip yüzlerce konteynerin, sınırlı bir alanda, birden fazla vinç (crane) tarafından eş zamanlı olarak işlenmesi, klasik optimizasyon yöntemlerinin yetersiz kaldığı, oldukça karmaşık ve dinamik bir problemidir.

Son yıllarda, Derin Pekiştirmeli Öğrenme (Deep Reinforcement Learning - DRL), özellikle Derin Q-Ağları (DQN) gibi algoritmalar, karmaşık ve belirsiz ortamlarda sıralı karar verme problemlerinin çözümünde kayda değer başarılar göstermiştir. Bu çalışma, liman konteyner istif sahasındaki operasyonları optimize etmek için, çok ajanlı (multi-

agent) bir DQN sisteminin tasarımı, geliştirilmesini ve analizini sunmaktadır. Projenin temel amacı, birden fazla vincin, gerçek dünya kısıtları altında (çarpışma, rotasyon, öncelik sırası, üst üste istifleme) birbiriyle koordineli bir şekilde çalışarak, verilen siparişleri en kısa sürede ve hatasız bir şekilde istif alanına yerleştirmesini sağlayan otonom bir kontrol sistemi geliştirmektir. Çalışma, problemin karmaşıklığını yönetmek için artımlı (incremental) bir metodoloji izleyerek, basit bir tek ajanlı sistemden başlayıp, operasyonel ve fiziksel tüm kuralları entegre ederek, nihayetinde tam otonom bir çok ajanlı sisteme ulaşmıştır.

2. PROBLEM TANIMI

Bu projede ele alınan temel problem, bir liman konteyner istif sahasının $N \times M$ boyutlarında bir ızgara (grid) yapısı olarak modellenmiş halinde, birden fazla otonom vincin koordinasyonudur. Problem, aşağıdaki alt problemleri ve kısıtları içermektedir:

Sıralı Karar Verme (Sequential Decision Making): Vinç-1'in (ana operatör), rastgele gelen sipariş listesindeki konteynerleri doğru öncelik sırasına (Yeşil > Sarı > Kırmızı) göre alıp, istif alanına taşınması gerekmektedir. Bu, her adımda bir aksiyon (yukarı, aşağı, sol, sağ, pickup, drop) seçmeyi gerektiren bir Markov Karar Süreci'dir (MDP).

Karmaşık Fiziksel ve Operasyonel Kısıtlar:

Çarpışma (Collision): Vinç-1, bir konteyner taşıırken diğer konteynerlerin üzerinden geçemez. Bu durum, sahanın dinamik bir engel haritasına dönüşmesine neden olur.

Rotasyon (Rotation): Konteynerler (örneğin, 1×3 veya 3×1 boyutlarında) istif alanına sığmadığında, ajan tarafından döndürülerek yerleştirilebilmelidir.

Çok Katmanlı İstifleme (3D Stacking): 3×3 veya 4×4 gibi sınırlı bir istif alanında, zemin kat dolduğunda, belirli kurallar çerçevesinde üst üste istifleme yapılabilirdir.

İş Kuralı Kısıtı (Priority Stacking): Üst üste istifleme sırasında, yalnızca düşük öncelikli konteynerler yüksek öncelikli olanların üzerine konulabilir (ör. Yeşil üstüne Sarı konulabilir, ancak Sarı üstüne Yeşil konulamaz).

Çoklu Ajan Koordinasyonu (Multi-Agent Coordination): Ana problem, Vinç-1'in yukarıdaki kısıtlar nedeniyle tıkanmasıdır. Özellikle büyük haritalarda, sipariş edilen bir konteynerin önü başka konteynerler tarafından kapatıldığında, Vinç-1'in hedefe ulaşması imkansızlaşır. Bu noktada, ikinci bir ajan olan Vinç-2 devreye girer. Vinç-2'nin görevi, Vinç-1'in rotası üzerindeki engelleyici konteynerleri tespit edip, onları geçici bir depolama alanına taşıyarak (re-location) ana operatörün yolunu açmaktır.

Bu projenin ana zorluğu, yukarıda bahsedilen tüm fiziksel ve operasyonel kısıtların, büyük bir durum-aksiyon uzayına (state-action space) sahip bir ortamda, iki bağımsız DQN ajanı tarafından eş zamanlı olarak öğrenilmesinin sağlanmasıdır. Özellikle harita ve konteyner

sayısı büyüdükçe, durum uzayının üstel olarak büyümesi (curse of dimensionality), eğitim süresini aşırı uzatmakta ve politikanın yakınsamasını zorlaştırmaktadır.

3. PROJEDE KULLANILAN YAKLAŞIMLAR

Artımlı ve Modüler Geliştirme (Incremental & Modular Development):

Projenin en temel yaklaşımıdır. Karmaşık bir problemi tek seferde çözmeye çalışmak yerine, sistem "basitten karmaşığa" prensibiyle adım adım inşa edilmiştir.

Faz 1: Sadece temel hareket ve taşıma görevlerini yapabilen tek vinçli basit bir ortam.

Faz 2: Fiziksel ve operasyonel tüm kısıtların (çarpışma, rotasyon, iş kuralları) sırayla sisteme entegre edilmesi.

Faz 3: İkinci vincin önce basit kurallarla (heuristic), sonra bir DQN ajanı olarak sisteme dahil edilmesi.

Faz 4: Sistemin daha büyük ve karmaşık haritalara ölçeklenmesi.

Çoklu Ajanlı Derin Pekiştirmeli Öğrenme (Multi-Agent Deep Reinforcement Learning)

Algoritma: İki bağımsız Derin Q-Ağı (Deep Q-Network - DQN) ajanı kullanılmıştır. Her bir vinç (Vinç-1 ve Vinç-2), kendi gözlemleri ve ortak bir ödül sinyali ile bağımsız olarak öğrenen birer ajandır.

Derin Q-Ağı (DQN) için Güncelleme Formülleri

Projenin ana öğrenme algoritması olan DQN'de, bir yapay sinir ağı, Q-değerlerini tahmin etmek için eğitilir. Eğitim sırasında kullanılan temel formüller şunlardır:

Optimal Q-Değeri (Bellman Denklemi)

Pekiştirmeli öğrenmenin temelini oluşturan bu denklem, bir durumda bir aksiyonun ne kadar iyi olduğunu ifade eder:

$$Q^*(s,a)=E[r+\gamma\max_{a'}Q^*(s',a')|s,a]$$

- $Q^*(s,a)$: ss durumunda aa aksiyonunun optimal değeri.
- r : Anlık ödül.
- γ : İndirim faktörü (projede **0.95** olarak kullanıldı). Gelecekteki ödüllerin bugünkü değerini belirler.
- $\max_{a'}Q^*(s',a')$: Bir sonraki s' durumunda yapılabilecek en iyi aksiyonun tahmini değeri.

Kayıp Fonksiyonu (Huber / MSE Loss)

$$L(\theta) = \mathbb{E}_{(s,a,r,s') \sim \text{Hafıza}} \left[\left(\underbrace{r + \gamma \max_{a'} Q_{\text{hedef}}(s', a'; \theta^-)}_{\text{Hedef Değer (Target)}} - \underbrace{Q_{\text{yerel}}(s, a; \theta)}_{\text{Tahmin (Prediction)}} \right)^2 \right]$$

- $Q_{\text{yerel}}(s,a;\theta)$: Yerel ağı (local network) o anki tahmini.
- $Q_{\text{hedef}}(s',a';\theta^-)$: Hedef ağı (target network) tahmini. Bu ağ, yerel ağı periyodik olarak kopyalanmasıyla oluşur ve eğitimi stabilize eder.
- θ : Yerel ağı ağırlıkları.
- θ^- : Hedef ağı ağırlıkları.

Merkeziyetsiz Eğitim: Ajanlar, kendi deneyim hafızalarını (replay buffer) kullanarak, birbirlerinden bağımsız olarak eğitilirler. Bu, literatürdeki "Independent Q-Learning" yaklaşımına benzer.

İş Birliği (Cooperation): İki ajan, ortak bir hedefi (tüm siparişlerin istiflenmesi) başarmak için iş birliği yapar. Vinç-1'in başarısı Vinç-2'yi, Vinç-2'nin engel kaldırması da Vinç-1'i olumlu etkiler.

Kural Tabanlı Uzman Sistemin Ajanlaştırılması (Heuristic-to-Agent Conversion)

Vinç-2 için DQN ile eğitilmeden önce kullanılan yaklaşım Heuristic yaklaşımını kullandık.

Projede kural tabanlı vinç için belirli bir matematiksel "öğrenme" formülü yoktur. Bunun yerine, ajanın davranışı deterministik bir karar ağacı (decision tree) ile belirlenir. Bu mantığın temelinde **Manhattan Mesafesi** ve bir Durum Makinesi (Finite State Machine) bulunur.

$$d(P,T)=|x_P-x_T|+|y_P-y_T|$$

Burada $P(x,y)$ vinçin mevcut konumu, $T(x_T,y_T)$ ise hedef konumdur.

Karar Algoritması (Öncelikli Yönelim):

Vinç, mesafeyi azaltmak için aşağıdaki öncelik sırasına göre hareket eder. Bu bir formülden ziyade bir **durum makinesi** kuralıdır:

Eğer $x_P < x_T$ ise **Aşağı** git. Eğer $x_P > x_T$ ise **Yukarı** git. Eğer $y_P < y_T$ ise **Sağa** git.

Eğer $y_P > y_T$ ise **Sola** git.

Eğer $d(P,T)=0$ ise ve hedef pickup ise **Pickup**, hedef drop ise **Drop** yap.

Prototipleme: Vinç-2'nin karmaşık görevi (engel kaldırma, geri koyma), öncelikle deterministik, kural tabanlı bir "uzman sistem" olarak modellenmiştir.

Doğrulama: Bu kural tabanlı sistemin simülasyonda başarılı bir şekilde çalıştığı görüldükten sonra, bir sonraki adıma geçilmiştir.

Otonomlaştırma: Kural tabanlı sistem, kendi DQN ağına sahip, otonom karar verebilen bir ajana dönüştürülmüştür. Bu, yazılım mühendisliğindeki "test stub'ından" gerçek modüle geçişe benzer bir mühendislik pratiğidir.

Karmaşık Kısıtların Ödül Şekillendirme ile Entegrasyonu (Constraint Integration via Reward Shaping)

Gerçek dünya operasyonel kuralları, ajanlara sadece engel olarak değil, öğrenmeleri gereken hedefler olarak sunulmuştur. Bu, ödül şekillendirme (reward shaping) ve ceza (penalty) mekanizmaları ile yapılmıştır:

Öncelik Kuralı: Doğru renk sırasıyla (Yeşil > Sarı > Kırmızı) alım yapana yüksek ödül (+8), yanlış sırada alım yapana yüksek ceza (-5) verilmiştir.

Fizik Kuralları: Duvara/engele çarpma cezası (-0.5) ve hedefe yaklaşma ödülü (+0.3) ile ajanın manevra yapması sağlanmıştır.

İş Birliği Kuralı: Vinç-2'nin bir engeli başarıyla kaldırmasına ödül (+5), Vinç-1'in işi bitince engelleri geri koymasına ise teşvik edici cezalar verilmiştir.

4. AKSİYON VE DURUM UZAYLARI

AKSİYON ID	EYLEM ADI	AÇIKLAMA
0	YUKARI	Vincin bir hücre yukarı hareket etmesi
1	AŞAĞI	Vincin bir hücre aşağı hareket etmesi
2	SOLA	Vincin bir hücre sola hareket etmesi
3	SAĞA	Vincin bir hücre sağa hareket etmesi
4	PICKUP	Vincin bulunduğu hücredeki konteyneri alması
5	DROP	Vincin taşıdığı konteyneri bulunduğu hücreye bırakması

Tablo 1: Aksiyonlar

Bileşen İndisi	Boyut	Değişken Adı	Açıklama	Bileşen İndisi	Boyut	Değişken Adı	Açıklama
0	1	crane1_pos[0] (Satır)	Vinç-1'in satır koordinatı.	57	1	Carrying2	Vinç-2'nin taşıma durumu.
1	1	crane1_pos[1] (Sütun)	Vinç-1'in sütun koordinatı.	58	1	target_pos[0]	Vinç-1'in taşıdığı konteyner için hedef satır. Sadece taşıma anında güncellenir.
2	1	crane2_pos[0] (Satır)	Vinç-2'nin satır koordinatı.	59	1	target_pos[1]	Vinç-1'in taşıdığı konteyner için hedef sütun. Sadece taşıma anında güncellenir.
3	1	crane2_pos[1] (Sütun)	Vinç-2'nin sütun koordinatı.	60	1	target_pos[2]	Vinç-1'in taşıdığı konteyner için hedef seviye (kat). Sadece taşıma anında güncellenir.
4-21	18	containers[i]['picked']	18 konteynerin her biri için alınma durumu.	61	1	next_pickup[0]	Vinç-1'in alması gereken bir sonraki siparişin satır koordinatı.
22-37	16	stacking_grid[r][c]	4x4'lük istif alanındaki her hücrenin en üstündeki konteynerin ID'si.	62	1	next_pickup[1]	Vinç-1'in alması gereken bir sonraki siparişin sütun koordinatı.
38-55	18	i in self.orders	18 konteynerin her biri için sipariş durumu.	63	1	expected_priority	Alınması beklenen konteynerin öncelik değeri.
56	1	carrying1	Vinç-1'in taşıma durumu.				

Tablo 2: Durum Uzağı Tablosu

5. ÖDÜL TABLOSU

DURUM	TÜRÜ	DEĞER	DURUM	TÜRÜ	DEĞER
Temel Adım Cezası	Ceza	-0,1	Yanlış Öncelikte Pickup	Ceza	-5,0
Duvara/Engele Çarpma	Ceza	-0,5	Başarısız Pickup Denemesi	Ceza	-2,0
Hedefe Yaklaşma Bonusu	Ödül	+0,3	Başarılı Drop (Sipariş Teslimi-N)	Ödül	+2.0 + 10.0 * N
Hedefe Uzaklaşma Cezası	Ceza	-0,3	Yanlış Yerde Drop	Ceza	-4,0
Pickup Noktasında Bekleme Cezası	Ceza	-0,5	Başarılı Engel Kaldırma (Vinç-2)	Ödül	+5,0
Başarılı Pickup	Ödül	+8,0	Tüm Siparişlerin Tamamlanması	Ödül	+20,0
Gereksiz Taşıma (Vinç-2)	Ceza	-2,0			

Tablo 3: Ödül Tablosu

6. EĞİTİM KURULUMU

Eğitim Kurulumu Parametreleri (10x10 Harita, Çift DQN Ajanı)

Parametre	Değer	Açıklama
Durum (State) Boyutu	64	Gözlem vektörünün uzunluğu (vinç konumları, konteyner durumları, istif alanı, vb.)
Aksiyon (Action) Boyutu	6	Her bir vinç için ayrıık eylem sayısı (yukarı, aşağı, sol, sağ, pickup, drop)
Ajan Sayısı	2	Bağımsız olarak eğitilen iki DQN ajanı (Vinç-1 ve Vinç-2)


Parametre	Değer	Açıklama
Ağ Mimarisi	512-512-256-128	Dört katmanlı tam bağlantılı (fully-connected) ağ; tüm katmanlarda ReLU aktivasyonu
Optimizasyon Algoritması	Adam	Gradyan inişi için kullanılan optimizör
Öğrenme Hızı (Learning Rate)	0.0003	Ağırlık güncellemelerinin adım büyüklüğü
Batch Boyutu	128	Her eğitim adımında hafızadan rastgele örneklenen deneyim sayısı
İndirim Faktörü (Gamma, γ)	0.95	Gelecekteki ödüllerin bugünkü değerini belirleyen katsayı
Başlangıç Keşif Oranı (Epsilon)	1.0	Eğitimin başında tamamen rastgele aksiyon seçme olasılığı
Minimum Epsilon	0.01	Keşif oranının düşebileceği alt sınır
Epsilon Azalma Katsayısı (Decay)	0.9995	Her eğitim adımından sonra epsilon değerini çarpan katsayı (yavaş azalma)
Hafıza (Replay Buffer) Boyutu	20,000	Saklanan maksimum deneyim (state, aksiyon, ödül, sonraki state) sayısı
Hedef Ağ Güncelleme Sıklığı	Her bölüm sonunda	<code>update_target_model()</code> her bölüm tamamlandığında çağrılır
Bölüm (Episode) Sayısı	2,000	Toplam eğitim bölümü sayısı
Maksimum Adım (Max Steps)	2,000	Bir bölümün uzunluğu (timeout)
Eğitim Donanımı	Google Colab (T4/L4 GPU)	Eğitim, ücretsiz/Pro GPU üzerinde gerçekleştirilmiştir
Toplam Eğitim Süresi (10x10)	~16 saat	Büyük harita ve iki ajandan dolayı oluşan uzun eğitim süresi (tahmini)

Küçük Harita (5x10) ile Karşılaştırma


Projenin geliştirme aşamasında kullanılan 5x10'luk küçük haritada parametreler şu şekildeydi:

Parametre	Küçük Harita (5x10)	Büyük Harita (10x10)
State Boyutu	35-45	64
Ağ Mimarisi	256-256-128	512-512-256-128
Batch Boyutu	64	128
Hafıza Boyutu	10,000	20,000
Öğrenme Hızı	0.0005	0.0003
Epsilon Azalma	0.999	0.9995
Bölüm Sayısı	1,500	2,000
Eğitim Süresi	~1-2 saat	~16 saat


7. Sonuçlar ve Grafikler



Şekil 1: Q-Learning 10x10 Eğitim Ödül Grafiği



Şekil 2: DQM 10x10 Eğitim Ödül Grafiği (11 Konteynır)



Şekil 3: DQM Çift Ajan Eğitim Ödül Grafiği (5x10 GRID)